

Báo cáo bài tập EX2.1: Data_Preprocessing

Bài tập 0: Sử dụng `sns.boxplot()` để quan sát đặc điểm phân bố dữ liệu của các trường số, mỗi trường này có outlier ko?

Sử dụng boxplot để quan sát phân bố của dữ liệu và phát hiện ngoại lai của từng trường dữ liệu trong vars


Gợi ý: `sns.boxplot(data_field)`

```
vars = ['price', 'total_sqft_float', 'price_per_sqft', 'balcony', 'bath', 'bhk']
```

```
plt.figure(figsize=(16,12))
```

#Code ở đây

```
sns.boxplot(x=df8['balcony'])
```



Nhận xét: Ngoài trường balcony, các trường khác đều có điểm ngoại lai.

Bài tập 1: Viết hàm bỏ đi các điểm dữ liệu có price per sqft dựa trên mean, std của các ngôi nhà dựa trên từng vị trí

Gợi ý: Xét trên từng vị trí (location), ngôi nhà thỏa mãn phải có

```
remove_pps_outliers(df):
```

#Code ở đây

```
#-----

temp=[]

for location, data in df.groupby('location'):

    m=data['price_per_sqft'].mean()

    s=data['price_per_sqft'].std()

    temp.append(data[(data['price_per_sqft']>m-s)&(data['price_per_sqft']<m+s)])

    return pd.concat(temp)

df9 = remove_pps_outliers(df8)

df9.shape
```

Output:

(0, 11)

Bài tập 2: Loại bỏ outlier xét theo trường bkh (số phòng)

Xét theo từng khu vực địa lí và theo từng loại nhà với số lượng phòng khác nhau, có một số ngôi nhà có giá không hợp lí (outliers), hãy tìm cách loại bỏ các outlier này. Cần ghi rõ quy tắc ghi nhận outlier

```
def remove_bhk_outliers(df):
```

```
    # Code ở đây
```

```
    #quy tắc loại: price_per_sqft của bhk lớn phải lớn hơn price_per_sqft trung bình
```

```
    temp=[]
```

```
    for bhk, data in df.groupby('bhk'):
```

```
        m=data['price_per_sqft'].mean()
```

```
        if bhk>5:
```

```
            temp.append(data[data['price_per_sqft']>m])
```

```
        else:
```

```
            temp.append(data)
```

```

return pd.concat(temp)

df10 = remove_bhk_outliers(df9)

df10.shape

```

Output:

```
(9171, 11)
```

Bài tập 3: Loại bỏ outlier khi xét trường 'bathroom'

df10.bath.unique() *#Có thể quan sát thấy một số căn nhà có số phòng tắm quá lớn (VD: 12!!!)*

```
array([1., 2., 3., 4., 5., 6., 7., 8., 9.])
```

```
df10[df10.bath > df10.bhk+2]
```

	area _typ e	avail abilit y	locatio n	size	total _sqft	b at h	balc ony	pri ce	total_sq ft_float	b h k	price_p er_sqft
11990	Super built-up Area	Ready To Move	Thanisandra	3 BHK	1806	6.0	2.00000	116.0	1806.0	3	6423.034330
7626	Built-up Area	Ready To Move	Chikka banavar	4 Bedroom	2460	7.0	2.00000	80.0	2460.0	4	3252.032520
11256	Built-up Area	Ready To Move	Nagasandra	4 Bedroom	7000	8.0	1.584376	450.0	7000.0	4	6428.571429

#Code ở đây, sao cho: df10[df10.bath < df10.bhk+2]

```
def remove_bath_outliers(df):
```

```
    temp=[]
```

```

for bath, data in df.groupby('bath'):

    temp.append(data[data['bath']<=(data['bhk']+2)])

return pd.concat(temp)

```

```
df11 = remove_bath_outliers(df10)
```

```
df11.shape
```

```
(9168, 11)
```

```
df11.head()
```

	area_ type	availa bility	locatio n	si ze	total _sqft	ba th	balc ony	pri ce	total_sq ft_float	b h k	price_p er_sqft
48 29	Built- up Ar ea	Ready To Move	Electro nic City	1 R K	435	1. 0	1.0	19 .5	435.0	1	4482.75 8621
10 47 1	Built- up Ar ea	Ready To Move	Electro nic City	1 R K	550	1. 0	1.0	27 .0	550.0	1	4909.09 0909
12 19 5	Super built- up Ar ea	Ready To Move	Mysore Highwa y	1 B H K	700	1. 0	1.0	25 .5	700.0	1	3642.85 7143
27 57	Super built- up Ar ea	20- Aug	Rache nahalli	1 R K	440	1. 0	0.0	28 .0	440.0	1	6363.63 6364


	area_ type	availa bility	locatio n	si ze	total _sqft	ba th	balc ony	pri ce	total_sq ft_float	b h k	price_p er_sqft
52 36	Super built- up Ar ea	18- May	Rache nahalli	1 R K	385 - 440	1. 0	0.0	19 .8	412.5	1	4800.00 0000

Quan sát lại kết quả sau khi xử lý với boxplot

```
plt.figure(figsize=(16,12))
```


```
sns.boxplot(x=df11['bath'])
```

(Dùng lại hàm đã code bên trên)



Bài tập 5*: Viết hàm trực quan hóa thể hiện mối tương quan giữa tổng diện tích (total_sqft) và giá nhà (price) theo từng vị trí địa lí (location) (tùy chọn minh họa theo 2 vị trí nào đó), của những căn nhà có 2 hoặc 3 phòng. Và cần phân biệt rõ điểm dữ liệu nào tương ứng với nhà có 2 phòng, điểm nào tương ứng với nhà có 3 phòng?

Gợi ý: Kết quả tương tự như hình dưới/ hoặc biểu đồ khác có ý nghĩa tương đương



#Gợi ý: Sử dụng plt.scatter() hoặc câu lệnh khác tương đương. Làm với df9

def plot_scatter_chart(df,location):

#Viết code ở đây

bhk2=df[(df.location==location)&(df.bhk==2)]

bhk3=df[(df.location==location)&(df.bhk==3)]

plt.figure(figsize=(15,10))

plt.scatter(bhk2.total_sqft_float, bhk2.price, color='blue', label='2 BHK', s=50)


plt.scatter(bhk3.total_sqft_float, bhk3.price,
marker='+', color='red', label='3 BHK', s=50)

plt.xlabel("Total Square Feet Area")


plt.ylabel("Price")

plt.title(location)

```
plot_scatter_chart(df9, "Rajaji Nagar")
```



```
plot_scatter_chart(df9, "Hebbal")
```



Bài tập 6*: Thực hiện các câu lệnh để trả lời các câu hỏi dưới đây:

- **Thống kê giá nhà theo từng loại khu vực (area_type). Làm với df9:**

- xem xét theo từng khu vực, thì giá nhà trung bình (price_per_sqft) là bao nhiêu, tương quan về giá nhà trung bình giữa các khu vực
- **Gợi ý:** Phần này có thể đưa ra kết quả dạng bảng hoặc biểu đồ (cột, histogram, ...).
- Sử dụng các lệnh: df.groupby(), df.sortvalues(), ... để trích xuất giá trị
- Sử dụng matplotlib: plt.bar(), ...

#Viết code ở đây

```
area_price = df9.groupby('area_type')['price_per_sqft'].mean()
```

```
area_price = area_price.sort_values()
```

```
print(area_price)
```

```
plt.figure(figsize=(10,6))
```

```
plt.bar(area_price.index, area_price.values)
```

```
plt.xlabel("Area Type")
```

```
plt.ylabel("Average Price per Sqft")
```

```
plt.title("Average Price per Sqft by Area Type")
```

```
plt.xticks(rotation=45)
```

```
plt.show()
```

```
area_type
```

```
Built-up Area    5552.880762
```

```
Super built-up Area  5570.537738
```

```
Carpet Area       5912.817970
```

```
Plot Area        8065.128865
```

```
Name: price_per_sqft, dtype: float64
```